SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 2293

Razvoj IoT-sustava za ranu detekciju prometnih nezgoda analizom audio-signala metodom dubokog učenja

Vito Zorić

Zagreb, lipanj 2026.

Sažetak

Ovaj završni rad istražuje i uspoređuje učinkovitost dvaju računalnih pristupa za automatsku klasifikaciju zvučnih anomalija u urbanim sredinama. Prvi pristup koristi klasični Piczak model temeljen na inženjerski definiranim značajkama i klasifikatoru šume stabala odluke [2], [10]. Drugi pristup primjenjuje naprednu arhitekturu Audio Spectrogram Transformer, koja mehanizmom samopažnje analizira log-Mel spektrogram signala [3], [14]. Rezultati pokazuju da fino podešeni AST model ostvaruje superiornu točnost od 97% do 99% te savršen odziv na kritičnim klasama prometnih nesreća. Rad pruža detaljnu analizu hardverske učinkovitosti na CUDA platformi, ističući izražen inženjerski kompromis između računalne složenosti i točnosti modela za ugradbene sustave.

Ključne riječi: AST; Piczak; Internet stvari; IoT; Pametni gradovi

Summary

This thesis investigates and compares the efficiency of two computational approaches for the automatic classification of acoustic anomalies in urban environments. The first approach utilizes the conventional Piczak model, based on hand-crafted features and a random forest classifier [2], [10]. The second approach employs the advanced Audio Spectrogram Transformer (AST) architecture, which analyzes the log-Mel spectrogram of the signal using a self-attention mechanism [3], [14]. The results demonstrate that the fine-tuned AST model achieves superior accuracy ranging from 97% to 99%, along with a perfect recall on critical car crash classes. Furthermore, this work provides a detailed hardware efficiency analysis on the CUDA platform, highlighting a distinct engineering trade-off between computational complexity and model accuracy for embedded systems.

Key words: AST; Piczak; Internet of Things; IoT; Smart cities

Sadržaj

Uvod 1

1. Internet of Things (IoT): teorija i arhitektura sustava 3

1.1. Koncept IoT sustava u pametnim gradovima 3

1.2. Arhitektura razvijenog IoT sustava 4

2. Podjela modela i skupova podataka 6

2.1. Piczak arhitektura za klasifikaciju zvuka temeljena na akustičkim značajkama 6

2.2. Audio Spektogram Transformer kao napredna duboka arhitektura 7

2.3. Koncept transfernog učenja i strategije finog podešavanja 8

2.4. Ustroj i priprema skupa podataka za binarnu klasifikaciju akustičkih anomalija 9

2.5. Prošireni višeklasni skup podataka 10

3. Implementacija bazičnog Piczak modela 11

3.1. Analiza rezultata binarne klasifikacije incidentnih situacija 11

3.2. Analiza rezultata na proširenom višeklasnom skupu podataka 12

4. Implementacija Audio Spectrogram Transformer modela 14

4.1. Rezultati i opis netrenirane arhitekture na binarnom i višeklasnom problemu 14

4.2. Rezultati binarne klasifikacije na CUDA platformi 15

4.3. Rezultati višeklasne klasifikacije na CUDA platformi 17

5. Komparativna analiza i rasprava rezultata 20

5.1. Usporedba procesorskog opterećenja i memorijskih zahtjeva modela 20

5.2. Kritički osvrt i preporuke za praktičnu implementaciju 21

Zaključak 22

Literatura 23

Izjava o korištenju umjetne inteligencije 25

Uvod

Automatska analiza i prepoznavanje akustičkih signala iz okoline predstavlja jedno od najdinamičnijih područja istraživanja u sferi obrade signala i strojnog učenja. Zvukovi iz okoline su gotovo uvijek izrazito nestacionarni, često preklopljeni s pozadinskim šumom te karakterizirani naglim promjenama energetske raspodjele unutar frekvencijskog spektra. Ovaj rad se usredotočuje na zvukove tog tipa koji su različiti od zvukova glasovne ili glazbene prirode čije su karakteristike najčešće strože vremenske, harmoničke i sintaktičke strukture. Pravovremena detekcija zvukova okoline, posebice onih koji upućuju na izvanredne situacije poput prometnih nesreća, ima kritičnu ulogu u razvoju suvremenih sustava nadzora, pametnih gradova i autonomnih vozila. Ova integracija omogućuje transformaciju urbanih sredina kroz inteligentno upravljanje sigurnosnim resursima [1]. Trenutačno postoje dva načina na koja se pristupa analizi i klasifikaciji zvukova, konvencionalni pristup i pristup duboke analize korištenjem strojnog učenja. Konvencionalni pristup se temelji na ručno definiranim akustičkim značajkama koji su najčešće kombinacija spektralnih deskriptora MFCC i klasičnih algoritma strojnog učenja poput šuma stabala odluke. Ovaj pristup zahtjeva najmanje resursa, izuzetno je učinkovit i brz, ali manjka na sposobnosti generalizacije pri radu s kompleksnim, visokodimenzionalnim šumom kontaminiram okruženjima. Ukratko, ovakav se pristup tradicionalno koristi u problemima akustičke klasifikacije zbog niske računalne složenosti [2]. Pristup duboke analize korištenjem strojnog učenja omogućila je izravno modeliranje sirovih spektrograma kao dvodimenzionalnih slika. Posljednjih šest do sedam godina napredovanja u metodama dubokog učenja postigle su da arhitekture temeljene na mehanizmu samopažnje, preuzete iz modela obrade prirodnog jezika tj. Transformeri, imaju izvanredne rezultate pri obradi i točnosti u računalnom vidu te na temelju toga i audiosignala. Taj napredni model temeljen na dubokom strojnom učenju je audio spektrogram transformer ilitiga AST. AST predstavlja upravo takvu naprednu arhitekturu koja u potpunosti napušta konvolucijske slojeve te primjenjuje mehanizam samopažnje na sekvence tih spektralnih isječaka. Uvođenjem ovog modela postignuti su vrhunski rezultati na standardnim skupovima zvučnih podataka [3]. Svrha ovog završnog rada je prikazati usporedbu ova dva pristupa analizama zvukova okruženja, koje metode postižu bolje i pouzdanije rezultate, koje su zahtjevnije, točnije i u kojim slučajevima su bolje od drugog

modela. Usporedba i analiza je provedena na dvije klasifikacije zvukova: binarna i višeklasna klasifikacija. Također unutar ovog rada provedena se i razlika u ponašanju AST modela s nasumično inicijaliziranim izlaznim slojem u usporedbi s modelom nad kojim je proveden proces nadziranog finog podešavanja na ciljanim skupovima podataka uz korištenje CUDA hardverske akceleracije. Rad isto donosi i detaljnu analizu hardverske učinkovitosti, procesorskog opterećenja i računalne složenosti, čime daje cjelovit uvid u opravdanost implementacije kompleksnih transformerskih modela u stvarnim sustavima. Struktura rada je organizirana u četiri poglavlja. Prvo poglavlje opisuje koncept IoT sustava i njegovu arhitekturu. Drugo poglavlje opisuje teorijske postavke klasične arhitekture analize i AST modela analize. Treće poglavlje posvećeno je implementaciji i analizi klasičnog modela, kasnije referiranog kao Piczak model, nazvan tako po znanstveniku koji je provodio i uspostavio temelj klasične analize. Treće poglavlje detaljno obrađuje AST model, i nasumično inicijaliziranog izlaznog sloja i modela nad kojim je provedeno fino podešavanje. Četvrto poglavlje se odnosi na sveobuhvatnu analizu, kritičku raspravu postignutih rezultata te evaluaciju hardverskih resursa utrošenih tijekom eksperimenata. Na kraju rada je iznesen zaključak s osvrtom na buduće smjernice razvoja.

1. Internet of Things (IoT): teorija i arhitektura sustava

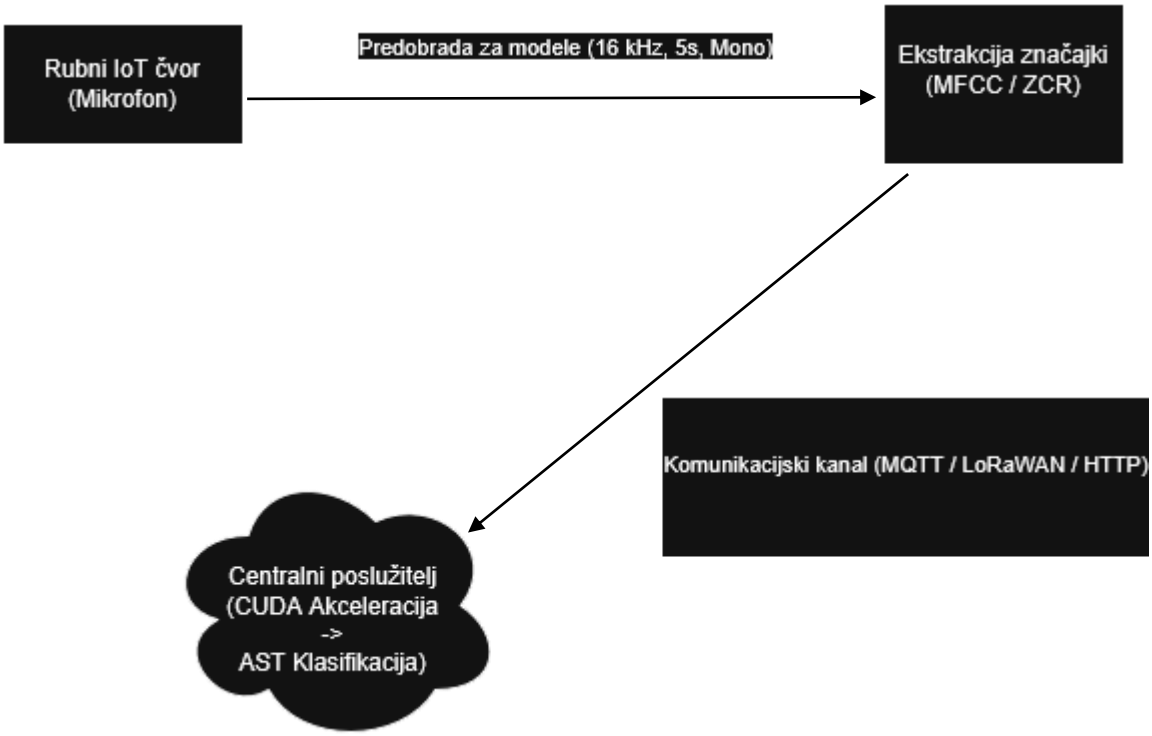
1.1. Koncept IoT sustava u pametnim gradovima

Internet stvari, tj na engleskom Internet of Things, je paradigmatski pomak u računalnoj znanosti gdje se svakodnevni fizički objekti povezuju na internet radi razmjene, obrade i prikupljanja podataka bez nužne ljudske intervencije. U kontekstu pametnih gradova, na engleskom Smart Cities, IoT sustavi imaju ključnu ulogu u tim gradovima kao što je podizanje razine javne sigurnosti, optimizaciji prometa i ranoj detekciji incidentnih situacija poput prometnih nezgoda, što potvrđuju i istraživanja u u ovom području [1]. Tipična arhitektura modernog IoT sustava sastoji se od tri osnovna sloja: zapažajni sloj, mrežni sloj i aplikacijski sloj [4]. Zapažajni sloj obuhvaća senzore koji prikupljaju sirove analogne signale iz okoline i pretvaraju ih u digitalni oblik, ukratko ovaj sloj bi se mogao opisati kao oči i uši IoT sustava. Mrežni sloj je odgovoran za siguran i pouzdan prijenos podataka putem specifičnih protokola, ovisno o tomu koji su potrebni u određenoj situaciji. Jedni od mogućih protokola su MQTT, HTTP ili LoRaWAN. Ovaj sloj se može opisati kao živčani sustav, prijenos informacija između senzora i centralnog sustava. Aplikacijski sloj je mjesto gdje se podaci obrađuju, analiziraju algoritmima strojnog učenja te se na temelju njih donose odluke, opisati se može kao mozak IoT sustava. U literaturi se uočava snažan trend prelaska s čistog računalstva u oblaku na računalstvo na rubu mreže. Kod obrade zvuka u stvarnom vremenu, slanje golemih količina neobrađenih podataka na udaljeni poslužitelj stvara probleme s propusnošću mreže i kašnjenjem. Zbog toga se u suvremenim arhitekturama teži implementaciji lakših algoritama izravno na rubne uređaje kako bi se obrada izvršila na samom izvoru podataka [5]. Integracija Interneta stvari (IoT) u urbane sredine predstavlja temeljni stup razvoja modernih pametnih gradova. Kroz implementaciju distribuiranih senzorskih mreža, gradska infrastruktura evoluira u koherentan sustav sposoban za kontinuirano prikupljanje heterogenih podataka iz okoline u stvarnom vremenu. Ovakav pristup omogućuje optimizaciju resursa, unaprjeđenje javne sigurnosti te automatizaciju odgovora na kritične događaje, poput prometnih nezgoda ili ekoloških ugroza, pretvarajući sirove informacije u podlogu za donošenje brzih odluka [1].

Uvođenje naprednih algoritama obrade podataka unutar ovakvog koncepta ključno je za postizanje visoke razine autonomije cjelokupnog urbanog ekosustava.

1.2. Arhitektura razvijenog IoT sustava

Kako se u ovom radu opisuje IoT sustav za nadzor prometa kako bi se ustanovila nesreća putem zvuka, ne može se izostaviti i opis srodnog sustava gdje se prati kroz računalni vid i analizu videonadzora. Videoanaliza ima značajna ograničenja u odnosu na analizu zvuka jer nepovoljni atmosferski uvjeti i loša vidljivost utječu na rezultate. S druge strane zvuk se širi sferno i ne ovisi o osvjetljenju i nema takvih problema kao videonadzor [6]. Postojeći sustavi u literaturi najčešće koriste fiksne mikrofonske rešetke na raskrižjima povezane s mikrokontrolerima koji koriste MFCC značajke u kombinaciji s potpornim vektorima ili jednostavnijim konvolucijskim mrežama. Glavni nedostatak sustava koji se temelje na klasičnim sustavima i analizi imaju visoku stopu lažnih pozitiva uzrokovanih kompleksnom i dinamičnom urbanom bukom [7], što u ovom radu se rješava uvođenjem naprednog transformatorskog modela. U sklopu ovog rada razvijen je koncept hibridnog IoT sustava namijenjenog ranoj detekciji prometnih nezgoda. Sustav je dizajniran kroz hijerarhijsku strukturu koja optimizira potrošnju energije i računalnih resursa: rubni IoT čvor, komunikacijski kanal i centralni poslužitelj. Arhitektura predloženog rješenja temelji se na hibridnom modelu koji kombinira koncepte rubnog računalstva (engl. edge computing) i centralizirane obrade u oblaku. Dok su rubni IoT čvorovi zaduženi za energetski učinkovito prikupljanje i lokalnu predobradu akustičkih signala na samom mjestu događaja, zahtjevne operacije dubokog učenja i masovno paralelnog računanja delegiraju se centralnom poslužitelju [5], [15]. Ovakva heterogena raspodjela računalnog tereta minimizira komunikacijsko zagušenje mreže, drastično smanjuje latenciju sustava u kriznim situacijama te osigurava skalabilnost sustava za primjenu na razini cijele gradske mreže. Detaljniji opisi svake metode, od osnovnog modela s nezahtjevnim algoritmima koji se mogu izvoditi na rubnom IoT čvoru do naprednijih transformatorskih modela koji zahtijevaju snažniju hardversku potporu i mogućih rješenja za implementaciju svih algoritama i sustava, slijede u drugim poglavljima.



Slika 1.2.1 Arhitektonska shema predloženog hibridnog IoT sustava od senzorskog čvora do centralnog poslužitelja (Izvor: vlastiti prikaz pomoću app.diagrams.net)

2. Podjela modela i skupova podataka

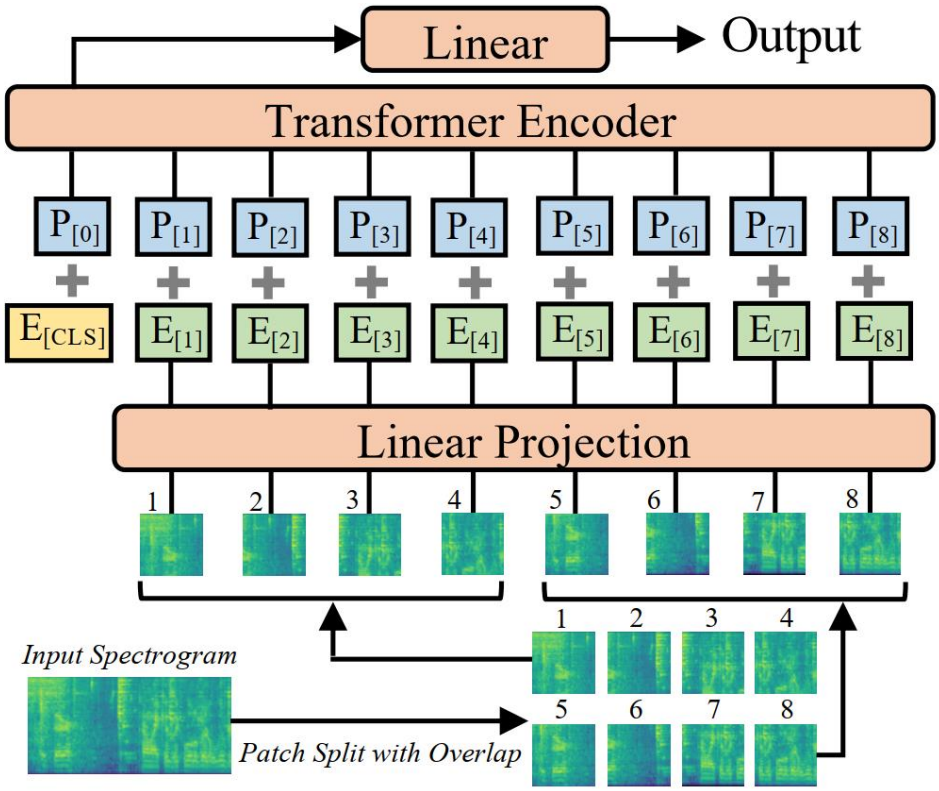
2.1. Piczak arhitektura za klasifikaciju zvuka temeljena na akustičkim značajkama

U području računalne obrade zvuka iz okoline, rad znanstvenika Karola J. Piczaka postavio je temelje za primjenu klasičnih metoda strojnog učenja na audiozapise [2]. Konvencionalni pristup klasifikaciji zvuka, u literaturi kao prije navedeno referiran kao Piczak model, ne analizira zvučni zapis u njegovom izvornom, sirovom vremenskom obliku jer digitalizirani zvučni val sadrži ogroman broj uzoraka u sekundi što predstavlja preveliku dimenzionalnost i računalni teret za klasične klasifikacijske algoritme. Kako bi se riješio problem preopterećenosti, Piczak pristup se oslanja na fazu ekstrakcije značajki gdje se u tom procesu uzorak zvuka matematički transformira i sažima u niz kompaktnih fizikalno-akustičkih deskriptora koji se nazivaju inženjerski definirane značajke tj. na engleskom hand-crafted features. Ovaj način analize zvuka podijeljen je na dvije ključne komponente: cepstralni koeficijenti na Mel-skali tj. skraćeno na engleskom MFCC i brzina prolaska kroz nulu tj. skraćeno na engleskom ZCR. MFCC je najvažnija značajka u klasičnoj obradi zvuka. Kako ljudsko uho ne percipira frekvencije linearno, zvučni signal se transformira pomoću brze Fourierove transformacije i filtrira kroz niz filtara poslaganih na toj tzv. Mel-skali koja oponaša ljudski sluh [13]. Rezultat svega je matematički sažetak, tj. cepstar, koji opisuje ukupnu „boju zvuka“ i energetski kostur tog primjerka zvuka kroz vrijeme. ZCR je jednostavniji, ali iznimno diskriminativan vremenski deskriptor koji mjeri koliko puta u sekundi zvučni val promjeni svoj predznak tj. broj prelazaka iz pozitivne vrijednosti u negativnu i obrnuto. Čisti, harmonični tonovi imaju nizak ZCR, dok nestrukturirani, oštri zvukovi te impulsni šumovi rezultiraju visokim ZCR. Nakon izračuna MFCC i ZCR, te se vrijednosti statistički agregiraju kako bi se dobio fiksni jednodimenzionalni vektor značajki za svaku datoteku. Taj se konačni vektor prosljeđuje klasifikatoru temeljenom na šumi stabala odluke tj. na engleskom Random Forest. U eksperimentu se koristila verzija Piczak arhitekture čiji su parametri izmijenjeni.

2.2. Audio Spektogram Transformer kao napredna duboka arhitektura

Suvremenija metoda obrada uzoraka zvukova je primjena transformatorskih arhitektura temeljenih na mehanizmu samopažnje. Predvodnik ove tehnologije u području analize uzoraka zvukova je Audio Spektrogram Transformer tj. skraćeno AST. Model je razvio na Massachusetts Institute of Technology Yuan Gong i suradnici [3]. AST u potpunosti napušta konvolucijske slojeve, prijašnja metoda primarno korištena za računalni vid, i koristi čistu transformatorsku arhitekturu koja uzorak promatra kao dvodimenzionalnu sliku frekvencije i vremena. Cjelokupni proces obrade unutar AST arhitekture odvija se kroz nekoliko ključnih faza: generiranje log-Mel spektrograma, rezanje na spektralne isječke, linearna projekcija i pozicijsko kodiranje te enkoder transformera i mehanizam samopažnje. Generiranje log-Mel spektrograma je najprije uzorkovanje na frekvenciju od 16 kHz jer je to standardni zahtjev modela. Zatim se primjenjuje kratkotrajna Fourierova transformacija s prozorom trajanja od 25 ms i pomakom od 10 ms. Na dobiveni spektrogram se primjenjuje filtar Mel-skale sa 128 kanala, čime se stvara dvodimenzionalna matrica log-Mel spektrograma koji predstavlja vizualni prikaz distribucije energije zvuka kroz frekvenciju i vrijeme. Rezanje na spektralne isječke je da model dvodimenzionalni spektrogram reže na niz malih, međusobno preklapajućih dvodimenzionalnih isječaka koji su obično veličine 16x16 elemenata te svaki isječak predstavlja specifičnu vremensko-frekvencijsku regiju zvuka. Linearna projekcija i pozicijsko kodiranja je gdje se svaki isječak veličine tih 16x16 linearno se poravnava u jednodimenzionalni vektor te projicira u prostor skrivene dimenzije. S obzirom na to da mehanizam samopažnje po svojoj prirodi ne vodi računa o poretku podataka, svakom vektoru se pribraja jedinstveni kod za poziciju tzv. pozicijsko kodiranje. Na taj način model zadržava informaciju kada se točno određeni frekvencijski događaj zbio u vremenu i na kojoj frekvenciji. Enkoder transformera i mehanizam samopažnje je gdje se pripremljeni niz vektora, zajedno s specijalnim klasifikacijskim tokenom, prosljeđuje kroz niz slojeva enkodera transformera. Srž ovoga je ukratko to što čini mehanizam samopažnje s više glava tj. na engleskom Multi-Head Self-Attention. Ovaj mehanizam omogućuje svakom spektralnom isječku da „pogleda“ i analizira sve ostale isječke u snimci istovremeno. Na taj način model računa međusobne korelacija i dinamički odlučuje koji su dijelovi spektrograma ključni za donošenje konačne odluke. Konačni prikaz zvuka

prikuplja se na izlazu enkodera na poziciji tokena te se prosljeđuje u linearni sloj koji daje konačne vjerojatnosti pripadnosti određenoj zvučnoj klasi.



Slika 2.2.1 Prikaz arhitekture Audio Spectrogram Transformer (AST) modela s mehanizmom rezanja spektrograma na isječke i enkoderskim blokovima (Izvor: [3])

2.3. Koncept transfernog učenja i strategije finog podešavanja

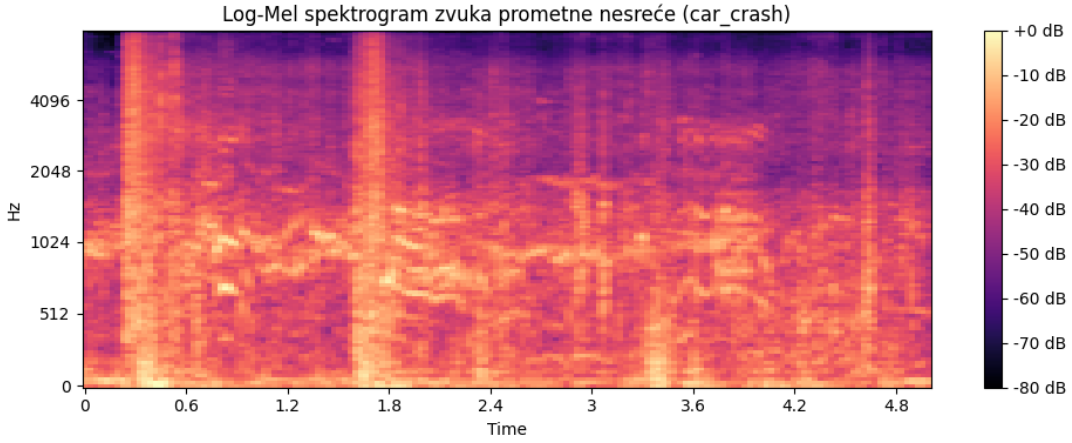
Treniranje dubokih neuronskih mreža, posebice kompleksnih arhitektura poput AST-a, izrazito je računalno zahtjevan proces koji zahtjeva milijune označenih uzoraka i dane, ili čak tjedne, računanja na grafičkim karticama. Kako bi se izbjegao taj problem, u modernoj umjetnoj inteligenciji primjenjuje se paradigma transfernog učenja. Transferno učenje je pristup u kojem se model prethodno istreniran na jednom masovnom skupu podataka koristi kao polazišna točka za rješavanje novog, specifičnog problema u srodnoj domeni tj. ovaj koncept omogućuje iskorištavanje prethodno naučenih općih značajki na novim, manjim skupovima podataka [8]. U sklopu ovog rada prvi korišteni AST model je razvijen i unaprijed istreniran na MIT-u pomoću AudioSet skupa podataka. AudioSet je masovni repozitorij koji sadrži preko dva milijuna audiozapisa raspoređenih u 527 ontoloških klasa

zvuka. Tijelo AST modela razvilo je iznimno robusne spektralne reprezentacije tijekom tog primarnog treniranja. Model je naučio kako prepoznati bazične elemente zvuka. Uzorke zvuka koji su izabrani van tog skupa podataka se daje tom modelu na obradu te se zabilježavaju rezultati. Međutim, ponašanje ovog modela prije i nakon procesa finog podešavanja, tj. na engleskom fine-tuning, radikalno se razlikuje, što je ključni predmet eksperimentalne analize u ovom radu. Proces finog podešavanja predstavlja strategiju kojoj se cijela mreža izlaže novom, specifičnom skupu podataka kroz manji broj epoha. Tijekom tog procesa pokreće se algoritam povratne propagacije u optimizacijski algoritam te je njihov primarni zadatak bio optimizirati i prilagoditi taj nasumično inicijalizirani izlazni sloj. Budući da su unutrašnje transformatorske značajke bile već iznimno bogate i formirane, izlazni sloj je u svega 5 epoha naučio savršeno interpretirati te vektore i povezati ih s ciljanim klasama.

2.4. Ustroj i priprema skupa podataka za binarnu klasifikaciju akustičkih anomalija

Za realizaciju prvog eksperimentalnog scenarija, binarne detekcije incidentnih situacija, formiran je namjenski skup podataka. Glavni cilj ovog podskupa je omogućiti modelima pouzdano razlučivanje između kritičnih zvučnih anomalija koje izravno upućuju na opasnost i uobičajenih, nekritičnih zvukova koji se svakodnevno pojavljuju u urbanom prostoru. Skup podataka podijeljen je u dvije diskretne kategorije: klasa accident (anomalija ili incident) i klasa no_accident (normalno okruženje). Accident klasa obuhvaća zvučne zapise koji sadrže specifične akustičke potpise prometnih nesreća poput silovitih udara motornih vozila, gužvanje lima, naglog kočenja, škripe guma i lomova automobilskog stakla. Ovi zvukovi su obilježeni izrazito visokom energijom u kratkom vremenskom intervalu i naglim spektralnim prijelazima. No_accident klasa služi kao kontrolna grupa i predstavlja standardnu zvučnu kulisu urbanog okruženja u kojoj nema neposredne ugroze te obuhvaća zvukove poput običnog cestovnog prometa, žamora ljudi na ulici, rada građevinskih strojeva, laveža pasa, šuma vjetra ili padanja kiše. Skup podataka prije same faze modeliranja je podijeljen na dio za treniranje i dio za testiranje tj. evaluaciju. Iz završnih evaluacijskih izvještaja vidljivo je da testni skup broji ukupno 212 uzoraka, dok kontrolni skup broji 200 uzorka. Ovako otprilike ujednačen omjer potvrđuje da je skup podataka statistički uravnotežen, pa to eliminira rizik od pojave algoritamske pristranosti i omogućuje objektivnu interpretaciju. Budući da se Piczak model i AST model

bitno razlikuju u načinu interpretacije zvuka, priprema podataka u kodu obuhvaća važne korake pretvorbe u duljinu od 5 sekundi i frekvencije od 16 kHz u mono. Svi zvučni zapisi su u nekomprimiranom formatu.



Slika 2.4.1 Vizualizacija log-Mel spektrograma testnog zvučnog zapisa iz klase car_crash s izraženim spektralnim prijelazom u trenutku udara (Izvor: vlastiti eksperimentalni rad)

2.5. Prošireni višeklasni skup podataka

Kako bi se evaluirala robusnost i diskriminativna moć razmatranih modela u znatno složenijem i realističnijem okruženju, formiran je prošireni višeklasni skup podataka. Dok binarna klasifikacija nudi jasan uvid u osnovnu sposobnost detekcije anomalija, u stvarnim okruženjima sustavi za nadzor moraju biti sposobni precizno klasificirati o kojoj se točno vrsti zvuka radi. Primjerice, sustav bi morao razlikovati zvuk prolaska vlaka od zvuka sirene vatrogasaca ili zvuk rada motorne pile od helikoptera kako ne bi došlo do lažnih uzbuna tj. pozitiva. Za potrebe obog eksperimenta, kreiran je namjenski skup podataka koji se temelji na priznatom i standardiziranom znanstvenom skupu podataka ESC-10, tj. na engleskom Environmental Sound Classification, koji je dodatno proširen i prilagođen specifičnom fokusu ovog rada [9] [10]. Skup podataka obuhvaća ukupno deset diskretnih kategorija koji se mogu podijeliti u tri skupine: anomalije, urbani i transportni šumovi i prirodni i tehnički izvori zvukova. Podjela je na 10 kategorija: car_crash, car_horn, chainsaw, crackling_fire, engine, fireworks, glass_breaking, helicopter, siren, train. Birani su posebno i na temelju sličnosti kako bi se moglo vidjeti koliko dobro sustav raspoznaje zvukove. Svaka od tih kategorija sadrži 10 zapisa, a sveukupno ih je 100.

3. Implementacija bazičnog Piczak modela

3.1. Analiza rezultata binarne klasifikacije incidentnih situacija

Prva faza eksperimentalnog dijela rada obuhvaća evaluaciju bazičnog Piczak modela na problemu binarne klasifikacije zvučnih zapisa. Glavni zadatak modela u ovom scenariju je prepoznavanje prisutnosti kritične anomalije, tj. klase accident, nasuprot uobičajenoj zvučnoj kulisi okoline, tj. klasa no_accident. Klasifikacija je provedena upotrebom ekstrahiranih MFCC i ZCR značajki koje su poslužile kao ulaz u trenirani klasifikator šume stabala odluke, tj. Random Forest. Nakon izvođenja evaluacije nad testnim skupom od 83 uzorka, Pizcak model postigao je ukupnu točnost od 78,31%. Kako bi se dobio dublji uvid u ponašanje modela, u nastavku se analiziraju parcijalne metrike prikazane po klasama u tablici 1.

Naziv kategorije	Preciznost (precision)	Odziv (recall)	F1-ocjena (f1-score)	Podrška (support)
accident	0,82	0,75	0,79	44
no_accident	0,74	0,82	0,78	39
Ukupna točnost/prosjek	0,78	0,75	0,78	83

Tablica 2.1 - Rezultat binarnog Pizcak modela

Preciznost predstavlja vrijednost koja pokazuje da od svih uzoraka koje je model proglasio da pripadaju nekoj klasi, koliko ih zapravo pripada klasi. Odziv predstavlja vrijednost koja pokazuje da od svih stvarnih uzoraka koji uistinu postoje u toj klasi, koliko ih je model uspio pronaći i točno klasificirati. Budući da su preciznost i odziv često u sukobu (balansu), F1-ocjena predstavlja njihovu harmonijsku sredinu. To je jedinstvena brojčana ocjena koja balansira oba faktora i daje realnu sliku o kvaliteti modela za pojedinu klasu. Vrijednost se kreće od 0, što je najgore, do 1, što je najbolje. Podrška predstavlja stvarni broj uzoraka koji pripadaju određenoj klasi unutar testnog skupa podataka.

3.2. Analiza rezultata na proširenom višeklasnom skupu podataka

Nakon binarne evaluacije, bazični Piczak model testiran je u znatno zahtjevnijem okruženju koje obuhvaća deset različitih kategorija zvukova. Cilj ovog eksperimenta je bio utvrditi sposobnost modela da razlikuje specifične zvučne događaje kada su oni okruženi sličnim, ometajućim šumovima iz urbanog prostora. Nakon provođenja klasifikacije nad testnim skupom od 91 uzorka, Piczak model je postigao ukupnu točnost od 77%. Iako je ovo blisko vrijednosti binarne klasifikacije, detaljan uvid u tablici 2 koja prikazuje sva mjerenja otkriva odstupanja od binarnog modela.

Naziv klase (kategorije)	Preciznost (precision)	Odziv (recall)	F1-ocjena (f1-score)	Podrška (support)
Car_crash	0,76	0,84	0,80	19
Car_horn	0,75	0,38	0,50	8
Chainsaw	0,67	1,00	0,80	8
Crackling_fire	1,00	0,75	0,86	8
Engine	0,56	0,62	0,59	8
Fireworks	0,88	0,88	0,88	8
Glass_breaking	0,89	1,00	0,94	8
Helicopter	0,62	0,62	0,62	8
Siren	0,88	0,88	0,88	8
Train	0,83	0,62	0,71	8
Ukupna točnost/prosjek	0,78	0,76	0,76	91

Tablica 1.2 - Rezultat višeklasnog Pizak modela

Može se primijetiti kako model gotovo savršeno funkcionira i klasificira zvukove kategorija poput glass_breaking i chain_saw, dok kod klasa car_horn i engine ostvaruje

dosta nisku preciznost i odziv. Primarna klasa car_crash drži stabilnu izvedbu s preciznošću od 76% i odzivom od 84%. Zaključno, višeklasni test dokazuje da bazični Piczak model gubi snagu kada se suoči s klasama koje imaju slične spektralne potpise. Sažimanje zvukova u grube statističke prosjeke koeficijenata briše ključne vremenske detalje, što potvrđuje inženjersku opravdanost uvođenja dubokih transformatorskih arhitektura koje analiziraju kompletan spektrogram.

4. Implementacija Audio Spectrogram Transformer modela

4.1. Rezultati i opis netrenirane arhitekture na binarnom i višeklasnom problemu

U ovoj fazi rada, AST je stavljen u funkciju neposredne klasifikacije zvuka bez provođenja inicijalnog procesa lokalnog učenja ili finog podešavanja. Cilj ovog eksperimenta bio je empirijski potvrditi ponašanje pretreniranog enkodera kada mu se, uslijed izmjene dimenzionalnosti izlaza, dodijeli potpuno novi i nasumično inicijalizirani klasifikacijski sloj. Pri pokretanju ispisano je upozorenje koje ukratko opisuje i detektira modifikaciju: originalni linearni sloj treniran na MIT-u za prepoznavanje 527 klasa uklonjen je, a na njegovo mjesto postavljen je novi linearni sloj prilagođen našim potrebama (2 klase za binarni i 10 klasa za višeklasni problem). Težinski faktori tog novog sloja generirani su pomoću nasumične distribucije brojeva, što znači da je izlazni sloj u ovoj fazi u potpunosti neoptimiziran. Model u ovom stanju je pokrenut nad testnim podskupovima obaju formiranih skupova podatak, a ostvareni rezultati se razlikuju i međusobno i od Piczak modela. Binarni problem je imao točnost od 57%, visoku pokrivenost klase no_accident s odzivom od 92%, ali izrazito loš odziv za klasu accident od svega 25%. F1-ocjena za detekciju nesreća iznosi kritično niskih 0,38. Višeklasni problem ima točnost svega 16%. Izvještaj po klasama otkriva da čak 6 od 10 klasa ima preciznost od 0,00.

Klasa	Preciznost (precision)	Odziv (recall)	F1-ocjena (f1-score)	Podrška (support)
Accident	0,79	0,25	0,38	44
No_accident	0,52	0,92	0,67	39
Točnost			0,57	83

Tablica 2.11 - Rezultat netreniranog binarnog AST modela

Naziv klase	Preciznost	Odziv (recall)	F1-ocjena (f1-	Podrška

(kategorije)	(precision)		score)	(support)
Car_crash	0,38	0,26	0,31	19
Car_horn	0,57	0,50	0,53	8
Chainsaw	0,19	0,38	0,25	8
Crackling_fire	0,00	0,00	0,00	8
Engine	0,00	0,00	0,00	8
Fireworks	0,00	0,00	0,00	8
Glass_breaking	0,00	0,00	0,00	8
Helicopter	0,22	0,25	0,24	8
Siren	0,00	0,00	0,00	8
Train	0,08	0,12	0,10	8
Točnost			0,16	91

Tablica 3.12 - Rezultat netreniranog višeklasnog AST modela

Zaključak ovih rezultata je je jednoznačan, a to je da niska točnost ne upućuje na nesposobnost AST modela, već ilustrira matematičku zakonitost teorije vjerojatnosti. Na uzorku od 2 klase, nasumično pogađanje teži rezultati od 50%, a ostvareno je 57%. Slično je i za višeklasni gdje nasumično je vjerojatnost 10%, a rezultat je 16%. Unutrašnjost AST modela generira dobre rezultate, ali nasumični izlazni sloj ih pretvara u matematički šum, a to dokazuje apsolutnu nužnost provođenja finog podešavanja.

4.2. Rezultati binarne klasifikacije na CUDA platformi

Kako bi se neutralizirale slabosti neoptimiziranog izlaznog sloja i u potpunosti iskoristio kapacitet AST arhitekture, nad modelom je proveden proces nadziranog finog podešavanja. Proces je proveden na računalnoj platformi opremljenoj grafičkim procesorom uz korištenje NVIDIA CUDA programske potpore, Upotreba CUDA akceleracije je bila potrebna zbog izrazito visoke računalne složenosti modela. Proces učenja nad binarnim skupom podatak konfiguriran je kroz 5 epoha. Svaka epoha predstavlja jedan cjeloviti

prolazak kroz cjelokupni skup podataka za treniranje. Unutar svake epohe, podaci su podijeljeni u mini-grupe, pri čemu je algoritam izvršio točno 42 iteracije ažuriranja težinskih faktora po epohi. Tijekom treniranja, primarni indikator konvergencije modela bila je funkcija gubitka unutar-klasne entropije, čija progresija kroz epohe glasi:

- Epoha 1: prosječni gubitak je 0,1235
- Epoha 2: prosječni gubitak je 0,0211
- Epoha 3: prosječni gubitak je 0,0111
- Epoha 4: prosječni gubitak je 0,0007
- Epoha 5: prosječni gubitak je 0,0004

Ovaj eksponencijalni pad vrijednosti prema nuli dokazuje iznimno brzu stabilizaciju i konvergenciju mreže. Budući da su unutrašnje reprezentacije značajki unutar samog transformera već bile pretrenirane na MIT-u, optimizacijski algoritam (AdamW) morao je tek minimalno prilagoditi unutrašnje težine enkodera [11], dok je primarno fokusirano mapiranje novog klasifikacijskog sloja prema ciljanim klasama. Ovo su rezultati prikazani u sljedećoj tablici.

Klasa	Preciznost (precision)	Odziv (recall)	F1-ocjena (f1-score)	Podrška (support)
Accident	1,00	0,98	0,99	43
No_accident	0,98	1,00	0,99	40
Točnost			0,99	83

Tablica 3.21 - Rezultat treniranog binarnog AST modela

Usporedba s netreniranom verzijom modela, gdje je točnost bila 56% i bazičnim Piczak modelom, koji iznosi 76%, ukazuje na potpunu dominaciju fino podešenog AST-a, koji doseže ukupnu točnost od 99%. Za klasu accident model postiže preciznost od 100%, što znači da model nije generirao nijednu lažnu uzbunu, a odziv od 98% da model je propustio klasificirati damo jednu snimku. Vrlo slični su rezultati za klasu no_accident.

4.3. Rezultati višeklasne klasifikacije na CUDA platformi

Nakon uspješne binarne optimizacije, najzahtjevniji dio eksperimentalnog istraživanja obuhvatio je provođenje procesa finog podešavanja nad proširenim višeklasnim skupom podataka od 10 kategorija. S obzirom da je netrenirani model prikazao degradaciju rezultata u odnosu na Piczakov za višeklasno, cilj je bio dokazati da se primjenom strukturiranog učenja i povratne propagacije unutrašnji transformatorski mehanizmi mogu uspješno mapirati na kompleksni, višeklasni sustav. Proces učenja se opet vodio kroz 5 epoha te se isto koristila hardverska akceleracija. Zbog veće složenosti problema, 10 klasa umjesto 2, optimizacijski algoritam je bio podvrgnut znatno većem broju iteracija ažuriranja težina po svakoj epohi. Konvergencija modela je opet praćena kroz metriku gubitka unutar-klasne entropije:

- Epoha 1: prosječni gubitak je 0,6559
- Epoha 2: prosječni gubitak je 0,1030
- Epoha 3: prosječni gubitak je 0,0325
- Epoha 4: prosječni gubitak je 0,0073
- Epoha 5: prosječni gubitak je 0,0038

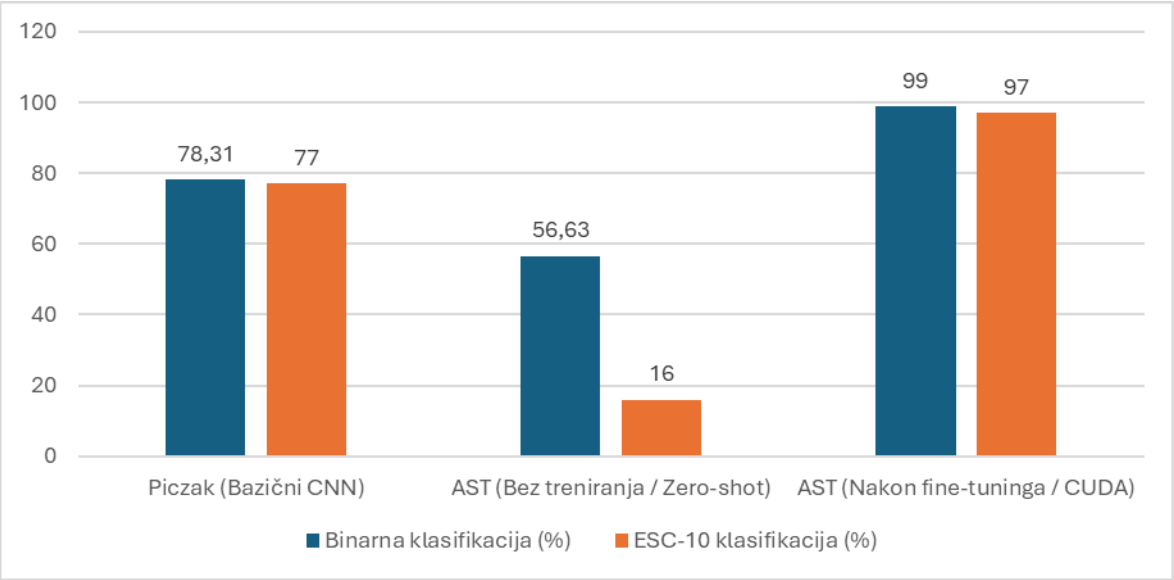
Kao što je vidljivo iz numeričkih pokazatelja, vrijednost funkcije gubitka u prvoj epohi bila je znatno viša nego u binarnom modelu. Razlog tomu leži u činjenici da je prostor odluke za deset kategorija eksponencijalno složeniji. Unatoč tome, do pete epohe gubitak je sveden na zanemarivu vrijednost, što ukazuje na uspješno dovršenu konvergenciju i stabilizaciju svih težinskih faktora. Rezultati su prikazani u sljedećoj tablici.

Naziv klase (kategorije)	Preciznost (precision)	Odziv (recall)	F1-ocjena (f1-score)	Podrška (support)
Car_crash	0,95	1,00	0,97	19
Car_horn	1,00	1,00	1,00	8
Chainsaw	1,00	1,00	1,00	8
Crackling_fire	1,00	1,00	1,00	8

Engine	1,00	0,88	0,93	8
Fireworks	1,00	1,00	1,00	8
Glass_breaking	1,00	1,00	1,00	8
Helicopter	0,89	1,00	0,94	8
Siren	1,00	0,88	0,93	8
Train	1,00	1,00	1,00	8
Točnost			0,97	91

Tablica 3.31 - Rezultat treniranog višeklasnog AST modela

Rezultati u tablici prikazuju izniman skok u odnosu na bazične modele te potvrđuju punu opravdanost implementacije transformerskih arhitektura. Najveći trijumf treniranog višeklasnog AST modela se očituje upravo na klasama na kojima je bazični Piczak model podbacio, gdje je kod Piczaka klasa sirene imala odziv od 38% dok ovdje ima 100%. Za 7 od 10 klasa imao je preciznost od 100%, što znači da rizik od lažnih uzbuna u tim kategorijama je eliminiran. Zaključno, ukupna postignuta točnost od 97% dokazuje da proces finog podešavanja AST arhitekture na CUDA platformi ne rezultira samo kozmetičkim poboljšanjima, već korjenito mijenja diskriminativne sposobnosti sustava. Mehanizam uspješno uči prepoznati fine, dvodimenzionalne vremensko-frekvencijske geometrijske oblike unutar spektrograma, čime se postiže robusnost koja je do sada bila nedostižna u klasičnoj obradi zvuka.



Slika 4.1 Usporedni prikaz ukupne točnosti bazičnog Piczak modela i arhitekture Audio Spectrogram Transformer (AST) prije i nakon procesa finog podešavanja (Izvor: vlastiti prikaz)

5. Komparativna analiza i rasprava rezultata

5.1. Usporedba procesorskog opterećenja i memorijskih zahtjeva modela

Pri implementaciji sustava za automatsku analizu i prepoznavanje zvukova u stvarnom svijetu, metrički pokazatelji točnosti algoritama čine samo polovicu jednadžbe. Druga, jednako kritična komponenta jest hardverska učinkovitost, koja definira računalnu opravdanost i izvedivost implementacije pojedinog modela na ciljanim infrastrukturnim sustavima. U ovom su poglavlju analizirani i uspoređeni zahtjevi za procesorskim opterećenjem, CPU u odnosu na GPU, vremenom izvršavanja (inferencije) te zauzećem radne i trajne memorije za bazični Piczak model i napredni AST model. Eksperimentalna mjerenja tijekom faze treniranja i faze testiranja pokazala su drastične razlike u arhuralnim zahtjevima ovih dvaju pristupa. Piczak model u potpunosti izvodi na CPU i pokazuje iznimno niske zahtjeve za resursima. Tijekom obrade signala i klasifikacije pomoću šume stabala odluke, opterećenje nije bilo veliko te zbog toga algoritam nije zahtijevao nikakvu hardversku akceleraciju. Trenirani AST model se temelji na čistoj transformatorskoj arhitekturi s mehanizmom samopažnje, njegova računalna složenost raste kvadratno s duljinom ulazne sekvence spektralnih isječaka. Pokušaj izvođenja ovog modela na CPU dovodi do zasićenja jezgri i skoka opterećenja na 100%, uz neprihvatljivo dugo vrijeme čekanja na rezultat. Zbog toga je model prebačen na NVIDIA CUDA platformu. Također postoji i razlika u veličini spremljenih datoteka i potrebi radne memorije. Piczak model ima puno manje opterećenje platforme, zauzima malo prostora za pohranu modela i zanemarivu količinu radne memorije zauzima. AST model je suprotan u tom pogledu gdje uzrokuje veliko opterećenje platforme do te mjere da je potrebna hardverska akceleracija, kao model zauzima puno više memorijskog prostora te zahtjeva veliku količinu radne memorije. Ovo jasno ukazuje na postojanje klasičnog kompromisa u računalnoj znanosti. Bazični Piczak model žrtvuje dio točnosti, ali nudi izuzetno veliku brzinu, dok AST nudi veliku točnost s velikim hardverskim zahtjevima i smanjenom brzinom.

5.2. Kritički osvrt i preporuke za praktičnu implementaciju

Na temelju provedenih eksperimenata, metričkih izvještaja i analize hardverske potrošnje, moguće je donijeti objektivan sud o primjenjivosti bazičnog Piczak modela i napredne AST arhitekture. Izbor optimalnog modela u praktičnim sustavima ne ovisi isključivo o matematičkoj točnosti, već o specifičnim projektnim zahtjevima, proračunu i dostupnoj računalnoj infrastrukturi. Preporuka je da se Piczak model implementira na uređaje s ograničenim resursima, poput Raspberry Pi, i na sustavima s baterijskim napajanjem jer nije energetski zahtjevan. Također se Piczak model može koristiti kao „prva linija obrane“ tj. kao brzi i lagani filter koji konstantno sluša okolinu na samom uređaju, a prilikom detekcije anomalije se ta snimka šalje na centralni server gdje kompleksniji model donosi odluku. Za AST model je preporuka da se koristi u sustavima gdje greška u klasifikaciji nije dopustiva pogreška poput autonomnih vozila ili okruženja gdje je visoka razina buke naprednog mehanizma samopažnje koji analizira cjelokupni kontekst log-Mel spektrograma, AST je neophodan u izrazito bučnim okruženjima gdje klasični spektralni deskriptori gube diskriminativnu moć.

Zaključak

U sklopu ovog završnog rada provedena je sveobuhvatna i rigorozna usporedba dviju računalnih metoda za automatsku analizu i klasifikaciju akustičkih signala iz okoline: Piczak model i AST model. Eksperimentalna evaluacija je izvršena na dvije razine složenosti, naime binarnoj i višeklasnoj te je još provedeno sustavno praćenje hardverske učinkovitosti na NVIDIA CUDA platformi. Empirijski rezultati nedvosmisleno pokazuju kako proces finog podešavanja rezultira dramatičnim skokom performansi, postižući ukupnu točnost od 99% na binarnom i 97% na višeklasnom problemu. AST model je u potpunosti eliminirao kritične nedostatke bazičnog modela, demonstrirajući savršen odaziv od 100% na klasama od primarnog sigurnosnog interesa, kao što su prometne nesreće i sirene. Međutim, rad donosi i i ključni inženjerski zaključak o postojanju izraženog kompromisa između točnosti i računalne složenosti. Iako je AST superioran u metričkim pokazateljima, on postavlja rigorozne hardverske zahtjeve. Nasuprot tomu, Piczak model troši vrlo malo snage CPU-a i zauzima minimalno memorijskog prostora što ga čini izuzetno održivim rješenjem za sustave s ograničenim resursima, unatoč nižoj točnosti ~77%. Buduće smjernice razvoja ovog istraživanja mogu se kretati u dva smjera. Prvi smjer je obuhvaćanje tehnika kvantizacije i destilacije znanja nad AST modelom, s ciljem kompresije njegovih parametara i memorijskog otiska kako bi se mogao koristiti na energetski učinkovitijem hardveru [12]. Drugi smjer je hibridna dvostupanjska arhitektura, u kojima bi Piczak model na samom rubu mreže služio kao stalni detektor anomalija, dok bi se računalno zahtjevni AST model aktivirao po potrebi na centralnom sustavu u trenutcima detekcije potencijalnog incidenta i potrebna je detaljnija analiza, čime bi se postigao optimalan balans između energetske održivosti i maksimalne sigurnosti u stvarnim sustavima aktivnog nadzora.

Literatura

[1] A. Zanella, N. Bui, A. Castellani, L. Vangelista, and M. Zorzi, “Internet of Things for Smart Cities,” IEEE Internet of Things Journal, vol. 1, no. 1, pp. 22–32, 2014. Dostupno na: https://ieeexplore.ieee.org/document/6740844

[2] K. J. Piczak, “Environmental sound classification with convolutional neural networks,” in 2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP), 2015, pp. 1–6. Dostupno na: https://ieeexplore.ieee.org/document/7324337

[3] Y. Gong, Y. A. Chung, and J. Glass, “Ast: Audio spectrogram transformer,” in Proc. Interspeech 2021, 2021, pp. 571–575. Dostupno na: https://arxiv.org/pdf/2104.01778.pdf

[4] J. Gubbi, R. Buyya, S. Marusic, and M. Palaniswami, “Internet of Things (IoT): A vision, architectural elements, and future directions,” Future Generation Computer Systems, vol. 29, no. 7, pp. 1645–1660, 2013. Dostupno na: https://www.science.smith.edu/~jcardell/Courses/EGR328/Readings/IoT%20Vision.pdf

[5] W. Shi, J. Cao, Q. Zhang, Y. Li, and L. Xu, “Edge Computing: Vision and Challenges,” IEEE Internet of Things Journal, vol. 3, no. 5, pp. 637–646, 2016. Dostupno na: https://cse.buffalo.edu/faculty/tkosar/cse710_spring20/shi-iot16.pdf

[6] Y. Liang and X. Liu, “A Real-Time Traffic Accident Detection System Using Audio Signal Processing on Edge Devices,” Sensors, vol. 21, no. 22, p. 7558, 2021. Dostupno na: https://www.mdpi.com/1424-8220/21/22/7558/pdf

[7] J. Park and K. Lee, “Environmental Sound Classification Using Deep Learning for Smart City Applications,” arXiv preprint arXiv:2008.03598, 2020. Dostupno na: https://arxiv.org/pdf/2008.03598.pdf

[8] F. Zhuang et al., “A Comprehensive Survey on Transfer Learning,” Proceedings of the IEEE, vol. 109, no. 1, pp. 43–76, 2021. Dostupno na: https://arxiv.org/pdf/1911.02685.pdf

[9] A. F. Syah, „Raw Audio of Accident and Crime Detection Dataset”, Kaggle, 2023. Dostupno na: https://www.kaggle.com/datasets/afisarsy/raw-audio-of-accident-and-crime-detection

[10] K. J. Piczak, “ESC: Dataset for Environmental Sound Classification,” in Proceedings of the 23. ACM International Conference on Multimedia, 2015, pp. 1015–1018. Dostupno na Githubu: https://github.com/karolpiczak/paper-2015-esc-dataset

[11] I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization,” in International Conference on Learning Representations (ICLR), 2019. Dostupno na: https://arxiv.org/pdf/1711.05101.pdf

[12] G. Hinton, O. Vinyals, and J. Dean, “Distilling the Knowledge in a Neural Network,” arXiv preprint arXiv:1503.02531, 2015. Dostupno na: https://arxiv.org/pdf/1503.02531.pdf

[13] S. Davis and P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” IEEE Transactions on Acoustics, Speech, and Signal Processing, vol. 28, no. 4, pp. 357–366, 1980. Dostupno na: https://ieeexplore.ieee.org/document/1163420

[14] Y. Gong, Y. A. Chung, and J. Glass, “Ast: Audio spectrogram transformer,” in Proc. Interspeech 2021, 2021, pp. 571–575. Dostupno na Githubu: https://github.com/YuanGongND/ast

[15] J. Chen and X. Ran, “Deep Learning With Edge Computing: A Review,” Proceedings of the IEEE, vol. 107, no. 8, pp. 1655–1674, 2019. Dostupno na: https://arxiv.org/pdf/1905.07601.pdf

Izjava o korištenju umjetne inteligencije

Tijekom izrade rada korištena je umjetna inteligencija. Korišten je Google Gemini Flash 3.5. Korišten je u svrhe pri pomoći oblikovanju rečenica, provjeravanja gramatičkih netočnosti, objašnjavanje pojmova, pronalazak i nabrajanje izvora informacija i pomoć pri razumijevanju specifičnih funkcija koda.

Osvrt na korištenje umjetne inteligencije: Generirani sadržaj je uvijek bio podvrgnut provjeri i pažljivom korištenju. Svaka informacija se provjeravala kako bi se utvrdila točnost i izbjegle halucinacije. Odgovori su bili izmijenjeni i nisu se izravno implementirali.

Izjava o korištenju umjetne inteligencije: Potvrđujem da sam tijekom izrade ovog završnog rada koristio umjetnu inteligenciju u skladu s Politikom primjerenog korištenja umjetne inteligencije na Fakultetu elektrotehnike i računarstva, te da umjetna inteligencija nije zamijenila moje kritičko razmišljanje niti moj doprinos.